

Relatório da Prática 02:

Funções úteis.Distribuição Gaussiana.

SOARES,D.S. – 2022104711

Departamento de Engenharia Elétrica,
Universidade Federal de Viçosa, Viçosa - MG
Email: dyuliano.soares@ufv.br

Resumo—Essa prática teve como objetivo demonstrar o comportamento de uma distribuição Gaussiana. Uma das mais importantes distribuições teóricas e práticas. Ela é muito utilizada na inferência estatística para modelar fenômenos da natureza ou experimentos controlados. A função $f(x)$ é uma curva simétrica, unimodal com forma de sino que, quando $\mu=0$ e $\sigma=1$, ela descreve uma distribuição denominada Normal padrão ou Normal reduzida.

Palavras chaves- Neurônio Artificial,Distribuição Gaussiana,Python.

I.INTRODUÇÃO

A distribuição normal, também conhecida como distribuição gaussiana, é uma curva simétrica em torno do seu ponto médio, apresentando assim seu famoso formato de sino [1]. A curva de distribuição normal (Figura 1) representa o comportamento de diversos processos nas empresas e muitos fenômenos comuns, como por exemplo, altura ou peso de uma população, a pressão sanguínea de um grupo de pessoas, o tempo que um grupo de estudantes gasta para realizar uma prova [2].




Fig.1:Comportamento da distribuição gaussiana para diferentes valores de média e variância.

Segundo [1], a distribuição normal pode ser usada para aproximar distribuições discretas de probabilidade, como por exemplo a distribuição binomial. A distribuição normal, além disso, pode ser utilizada no

domínio da inferência estatística clássica. A distribuição uniforme (Figura 2), por sua vez, é uma distribuição de probabilidades contínua. Ou seja, a probabilidade de gerar qualquer ponto em um intervalo contido no espaço amostral é proporcional ao tamanho do intervalo [3].




Fig. 2: Distribuição uniforme

II.REFERENCIAL TEÓRICO

A distribuição normal (ou gaussiana) é uma ferramenta muito utilizada no campo da estatística, sendo uma das distribuições de probabilidade mais utilizadas para se descrever fenômenos naturais. Logo, para o estudo e entendimentos dos conceitos acerca das atividades abordadas pela prática, faz-se necessário conhecimento anterior acumulado sobre alguns conceitos de estatística, como por exemplo o de variáveis aleatórias, média aritmética, variância, desvio padrão, esperança e distorção [3].

De acordo com [5], uma variável aleatória pode ser entendida como uma variável

quantitativa. Nesse sentido, o resultado depende de fatores aleatórios, de forma que o estudo de estatística gira em torno da análise destas variáveis e como pode ser feita a sua caracterização e classificação.

Logo, a média aritmética é obtida a partir da soma dos valores de um conjunto de dados, dividindo-se o valor obtido pelo número de dados observados desse conjunto. Além disso, o valor é utilizado como uma medida da tendência central dos dados analisados. O seu cálculo pode ser feito como uma média simples, como descrito anteriormente, onde todos os dados possuem a mesma importância, ou pode-se atribuir pesos diferentes para cada um dos dados. No caso de uma média aritmética ponderada, o seu valor é dado pelo somatório dos dados multiplicados pelos seus respectivos pesos, dividido pelo somatório dos pesos. A equação da média é descrita pela Equação 1, onde x_i é um dos dados e p_i é o seu respectivo peso.

$$M_p = \frac{x_1 p_1 + x_2 p_2 + \dots + x_n p_n}{p_1 + p_2 + \dots + p_n}$$

$$M_p = \frac{\sum_{i=1}^n x_i p_i}{\sum_{i=1}^n p_i}$$

Para a maioria dos casos, pode-se considerar que a esperança de uma dada variável é igual a sua média. A notação da esperança da variável X pode ser escrita como $E[X]$. Conforme sabemos o desvio padrão e a variância, existe uma relação quadrática entre eles, sendo que a variância é o quadrado do desvio padrão. Ambas as medidas revelam a quantidade de dispersão média entre cada dado individual e a média do conjunto.

III. OBJETIVOS GERAIS E ESPECÍFICOS

O objetivo desse trabalho consiste na implementação de uma rotina que gere uma classe com distribuição gaussiana tomando como variáveis de entradas os parâmetros de distribuição (média e variância) e a saída como os vetores de abscissa e ordenada. Dito isso, é proposta uma rotina para geração de classe com distribuição uniforme.

IV. MATERIAIS E MÉTODOS

Com base nos conceitos apresentados anteriormente, foi implementada uma rotina no

PYTHON, a fim de gerar uma classe de dados com distribuição gaussiana, tendo como parâmetros de entrada a variância e o desvio padrão desejado, além da quantidade de dados a serem gerados para esta classe. Foi feito uso de algumas funções já existentes no PYTHON como podemos ver abaixo.

```
import numpy as np
from matplotlib import pyplot
as plt

def gaussianDistribution(mean,
    variance, numPoints):
    sigma = np.sqrt(variance)
    return np.random.normal(me
an, sigma, numPoints)

def uniformDistribution(a, b,
numPoints):
    return np.random.uniform(a
, b, numPoints)

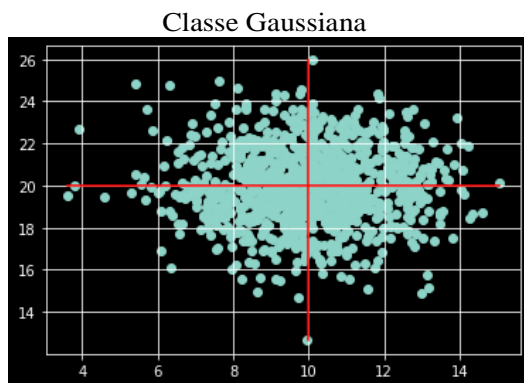
def measureDistortion(series):
    x, y = series
    dxy = 10 * np.log10(np.mea
n(x-y)**2/np.mean(x**2))
    return dxy

def plot(x, y):
    with plt.style.context('da
rk_background'):
        plt.scatter(x, y)
        plt.plot([np.mean(x), n
p.mean(x)], [np.min(y), np.ma
x(y)], color='red')
        plt.plot([np.min(x), n
p.max(x)], [np.mean(y), np.mea
n(y)], color='red')
        plt.grid()
        plt.show()

def main():
    x, y = gaussianDistributio
n(10, 3, 1000), gaussianDistri
bution(20, 3, 1000)
    print(measureDistortion((x
, y)))
    plot(x, y)
```

```
if __name__ == '__main__':
    main()
```

É interessante ressaltar que o gráfico criado durante essa prática foi produzido com o uso da função `scatter`. Logo, a função `plot` realiza a interpolação dos pontos, o que não é desejado nesse caso.



A figura acima 4 mostra a classe gaussiana obtida. É interessante ressaltar que os valores estão mais concentrados no centro do gráfico. Uma vez que é onde se encontra o valor médio. Logo, essa centralização dos valores são esperados para esse tipo de distribuição. Portanto, o comportamento deste resultado condiz com o gráfico de probabilidade mostrado na figura 1.

V. CONSIDERAÇÕES FINAIS

Esse trabalho apresentou rotinas capazes de gerar distribuições uniformes e gaussianas, bem como o cálculo de distorção de dados. Os resultados obtidos da distribuição correspondem para o esperado do perfil particular.

Na distribuição gaussiana, foi possível notar que os valores ficam mais centralizados em torno de seu valor médio, sendo que a distribuição uniforme é melhor distribuída dentro do intervalo dos dados observados. Portanto, a distribuição uniforme apresenta densidade de pontos constante em seu intervalo. Portanto, a distribuição gaussiana tem maior densidade em locais próximos a média.

VI. REFERÊNCIAS

Spatti D. Flauzino R. Nunes, I. Redes Neurais Artificiais para Engenharia e Ciências Aplicadas. Artliber, 2010.

Zsolt László Kovács. Redes neurais artificiais. Editora Livraria da Física, 2002.

Leandro FLECK, Maria Hermínia Ferreira Tavares, Eduardo Eyng, AC Helmann, and MA de M Andrade. Redes neurais artificiais: Princípios básicos. Revista Eletrônica Científica Inovação e Tecnologia, 1(13):47–57, 2016.

FCC De Castro and MCF De Castro. Redes neurais artificiais. DCA/FEEC/Unicamp, 2001.

<https://colab.research.google.com/drive/1A5Ozb6Qmr71XBgKvSs-1Wg0RjqAZIWXD#scrollTo=3Zgh0dkt5r13>

https://pt.wikipedia.org/wiki/Distribui%C3%A7%C3%A3o_normal

